

HURMA TÜRLERİ GÖRÜNTÜ SINIFLANDIRMA PROJESİ

1. Giriş (Introduction)

Tarım teknolojilerinde yapay zekâ uygulamaları, özellikle ürün sınıflandırma ve kalite kontrol süreçlerinde kritik bir rol oynamaktadır. Bu proje kapsamında, farklı hurma türlerinin görüntü işleme teknikleri ve derin öğrenme algoritmaları kullanılarak otomatik olarak sınıflandırılması hedeflenmiştir.

Çalışmanın temel amacı, görsel veriler üzerinden 9 farklı hurma türünü yüksek doğruluk oranıyla ayırt edebilen bir model geliştirmektir. Bu doğrultuda %95 ve üzeri doğruluk hedefi belirlenmiş ve farklı transfer learning mimarileri karşılaştırmalı olarak analiz edilmiştir.

2. Proje Amacı (Objective)

Bu projenin ana hedefi:

- 9 farklı hurma türünü (örneğin Ajwa, Medjool vb.) sınıflandırmak
- %95'in üzerinde doğruluk (accuracy) elde etmek
- Farklı derin öğrenme mimarilerinin performanslarını karşılaştırmak
- En iyi modeli belirleyerek gerçek dünya uygulamalarına uygun hale getirmek

3. Kullanılan Donanım ve Ortam (Hardware & Environment)

Model eğitimi ve deneyler aşağıdaki altyapı üzerinde gerçekleştirilmiştir:

- Platform:** Kaggle Notebook (Cloud Environment)
- GPU:** Tesla T4 (2 adet GPU kullanımı)
- Framework:** TensorFlow / Keras
- Programlama Dili:** Python

Bulut tabanlı GPU kullanımı sayesinde büyük veri setleri üzerinde hızlı eğitim ve hiperparametre optimizasyonu sağlanmıştır.

4. Metodoloji (Methodology)

Bu projede iki farklı yaklaşım uygulanmıştır:

1. Scratch CNN Model:

- 5 Convolutional Layer
- 3 Pooling Layer
- Dropout ve Batch Normalization ile regularization
- Activation: ReLU
- Output: Softmax

2. Transfer Learning Modelleri:

- ResNet50
- MobileNetV2
- InceptionV3
- Xception

Bu modeller önceden eğitilmiş ağırlıklarla kullanılmış ve son katmanları yeniden eğitilmiştir.

Loss Function: Categorical Crossentropy

Optimizer: Adam

4.1 Veri Ön İşleme

- Görüntülerin yeniden boyutlandırılması (resize)
- Normalizasyon işlemleri
- Eğitim/validasyon/test veri ayrımı
- Veri artırma (data augmentation):
 - Döndürme (rotation)
 - Yansıtma (flip)
 - Zoom

4.2 Model Mimarileri

Aşağıdaki önceden eğitilmiş CNN mimarileri kullanılmıştır:

- ResNet50
- MobileNetV2
- InceptionV3
- Xception

Her modelin son katmanları yeniden düzenlenerek (fine-tuning) hurma sınıflandırma problemine uyarlanmıştır.

5. Deneysel Sonuçlar (Experimental Results)

Farklı modellerin performansları aşağıdaki gibi ölçülmüştür:

5.1 Scratch CNN Model:

- **Doğruluk (Accuracy):** %86.93
 - **Kayıp (Loss):** 0.429
-

5.2 ResNet50 (En İyi Model – Şampiyon)

- **Doğruluk (Accuracy):** %98.78
- **Kayıp (Loss):** 0.0528

ResNet50 modeli, residual (skip connection) yapısı sayesinde derin katmanlarda bilgi kaybını minimize ederek en yüksek performansı elde etmiştir. Özellikle hurma yüzeyindeki:

- Mikro çatlaklar
- Renk ton geçişleri
- Doku farklılıkları

gibi ince detayları başarıyla öğrenmiştir.

5.3 MobileNetV2

- **Doğruluk:** %93.92

Düşük parametre sayısına rağmen oldukça güçlü bir performans sergilemiştir. Hafif yapısı sayesinde:

- Mobil uygulamalar
- Edge AI sistemleri

için en uygun aday modeldir.

5.4 InceptionV3

- **Doğruluk:** %93.01

Paralel evrişim (convolution) yapıları sayesinde farklı ölçeklerdeki özellikleri yakalayabilmiştir. Ancak ResNet50'nin sağladığı derin temsil gücüne ulaşamamıştır.

5.5Xception

- **Doğruluk:** %86.32

Depthwise separable convolution yapısına sahip olmasına rağmen beklenen performansı gösterememiştir. Bunun temel sebepleri:

- Daha fazla veri ihtiyacı
- Daha uzun eğitim süresi (epoch) gereksinimi

olarak değerlendirilmiştir.

6. Tartışma (Discussion)

Elde edilen sonuçlar, transfer learning yaklaşımının sınırlı veri setlerinde bile oldukça yüksek performans sağlayabildiğini göstermektedir.

Özellikle:

- ResNet mimarisinin residual bağlantıları
- Derin katmanlarda gradyan kaybını engellemesi

modelin başarısında belirleyici olmuştur.

MobileNetV2 ise performans/verimlilik dengesi açısından dikkat çekici olup, gerçek zamanlı sistemlerde kullanılabilirliği yüksektir.

7. Refleks (Reflection)

Bu proje sürecinde en önemli çıkarım, transfer learning yaklaşımının sınırlı veri setlerinde çok daha etkili olduğudur.

Scratch CNN modeli makul sonuçlar üretmiş olsa da, feature extraction kapasitesi sınırlı kalmıştır. Buna karşılık transfer learning modelleri önceden öğrenilmiş özellikleri kullanarak çok daha yüksek doğruluk elde etmiştir.

Gelecekte:

- Daha büyük veri seti kullanılabilir
- Hyperparameter tuning geliştirilebilir
- Daha gelişmiş regularization teknikleri uygulanabilir

Bu çalışma, CNN mimarilerinin ve transfer learning yaklaşımlarının karşılaştırmalı olarak anlaşılması açısından oldukça öğretici olmuştur.

8. Sonuç ve Gelecek Çalışmalar (Conclusion & Future Work)

Bu proje kapsamında:

- 9 farklı hurma türü başarıyla sınıflandırılmış
- %95 hedefi aşılmış (%98.78 ile)
- En iyi model olarak ResNet50 belirlenmiştir